

χ^2 检验

Chi-square test

χ^2 检验(Chi-square test)是现代统计学的创始人之一，英国人K. Pearson (1857-1936)于1900年提出的一种具有广泛用途的统计方法，可用于两个或多个率间的比较，计数资料的关联度分析，拟合优度检验等等。

第一节

四格表资料 χ^2 检验

表1 四格表资料的基本形式

处理组	阳性事件 发生数	阳性事件 未发生数	合计
甲	a	b	$a+b$
乙	c	d	$c+d$
合计	$a+c$	$b+d$	n

χ^2 检验的基本思想

$$\chi^2 = \sum \frac{(A - T)^2}{T}$$

A 为实际频数(actual frequency)

T 为理论频数(theoretical frequency)

理论频数的计算公式：

某行合计

某列合计

$$T_{RC} = \frac{n_R n_c}{n}$$

公式中的**R**表示行，**C**表示列。

某行某列的理论频数

(1) 非连续性校正 χ^2 值(Pearson χ^2 统计量)

$$\chi^2 = \sum \frac{(A-T)^2}{T}$$

$$\chi^2 = \frac{(ad-bc)^2 n}{(a+b)(a+c)(b+d)(c+d)}$$

$$\chi^2 = \frac{(ad-bc)^2 n}{(a+b)(c+d)(a+c)(b+d)} = 6.565$$

(2) 连续性校正 χ^2 值(Yates校正 χ^2 统计量)

$$\chi_c^2 = \sum \frac{(|A - T| - 0.5)^2}{T}$$

$$\chi_c^2 = \frac{(|ad - bc| - n/2)^2 n}{(a+b)(a+c)(b+d)(c+d)}$$

四格表 χ^2 值的计算:

1. $T > 5$ 及 $n > 40$

$$\chi^2 = \sum \frac{(A - T)^2}{T}$$

$$\chi^2 = \frac{(ad - bc)^2 n}{(a + b)(a + c)(b + d)(c + d)}$$

2.1<T<5及n>40

$$\chi^2 = \sum \frac{(|A - T| - 0.5)^2}{T}$$

$$\chi^2 = \frac{(|ad - bc| - n/2)^2 n}{(a + b)(a + c)(c + d)(b + d)}$$

3. $T < 1$ 或 $n < 40$

Fisher精确概率法

第二节 配对四格表资料的 χ^2 检验

(McNemar's test for correlated proportions)

配对资料的四格表资料特点是对样本中各观察单位分别用两种方法处理，然后观察两种处理方法的二分类结果。

表2 配对资料的四格表形式

		乙处理	
		+	-
甲处理	+	a	b
	-	c	d

McNemar's test / 配对 χ^2 检验

$H_0 : B = C$ （两总体对子数相等）

$b + c > 40$ 时，不需要校正

$$\chi^2 = \frac{(b - c)^2}{b + c}, \quad \nu = 1$$

$b + c < 40$ 时，连续性校正

$$\chi^2 = \frac{(|b - c| - 1)^2}{b + c}, \quad \nu = 1$$

$R \times C$ 表/列联表资料的 χ^2 检验

一、多个样本率的比较

二、两组或多组构成比的比较

三、行 $\times$ 列表分类资料的关联性分析

$$\chi^2 = n \left(\sum \frac{A^2}{n_R n_C} - 1 \right), \quad \nu = (R-1)(C-1)$$

$R \times C$ 表 χ^2 检验的条件

 理论频数不宜太小

1. 增大样本容量
2. 删去理论频数太小的格子所对应的行或列
3. 合并理论频数太小的格子所相邻的行或列

三. 双向无序分类资料的关联性检验

行、列属性都为无序的，常分析行、列两变量之间有无关系及关系的密切程度

Pearson列联系数**C**为：

$$C = \sqrt{\frac{\chi^2}{n + \chi^2}}$$

四格表资料的Fisher确切概率法


当 $n < 40$ 或 $T < 1$ 时，用Fisher确切概率法（fisher probabilities in 2×2 table）。

基本思想

其理论依据是超几何分布（hypergeometric distribution）。在四格表周边合计不变的条件下，直接计算表内四个数据的各种组合之概率。可按以下公式计算概率 P_i 。

$$P_i = \frac{(a+b)!(c+d)!(a+c)!(b+d)!}{a!b!c!d!n!}$$

基于秩次的非参数检验



假设检验 { 参数假设检验
非参数假设检验

总体分布已知,
检验关于未知参数
的某个假设

总体分布未知时
的假设检验

- ◆ 非参数统计分析方法(**non-parametric statistics**)
- ◆ 不拘分布 (**distribution-free statistics**)
- ◆ 无分布形式假定 (**assumption free statistics**)

非参数分析方法的优缺点

- **优点：** 不受总体分布条件的限制，适用范围广，某些不便准确测定，只能以严重程度，好坏优劣，次第先后等作记录的资料也可应用。
- **缺点：** 适用于参数检验的资料若用非参数检验会造成信息的丢失，导致检验功效下降。即当 H_0 不真时，非参数检验可能不如参数检验能较灵敏地拒绝 H_0 ，犯第二类错误的概率比参数检验大。

本章内容：

第一节 配对样本比较的Wilcoxon符号秩检验

第二节 两个独立样本比较的Wilcoxon秩和检验

第三节 完全随机设计多个样本比较的Kruskal-Wallis H 检验

第四节 随机区组设计多个样本比较的Friedman M检验

第五节 多个样本间两两比较的秩和检验

注 意

1. 非参数检验不对参数作明确的推断，也不涉及样本取自何种分布的总体；适用范围较广；常用的非参方法较为简便；当资料适用参数检验方法时，用非参常会损失部分信息，降低检验效能。
2. 秩和检验是通过对数据依小到大排列秩次，求秩和来进行假设检验的方法，可用于两独立样本比较、配对资料比较、多组样本比较等。

秩和检验适用的资料特点

- 半定量资料即等级资料
- 偏态分布
- 资料分布类型不明确
- 个别数据偏离过大或数据某一端的值不确定
- 各组离散程度相差悬殊

两变量关联性分析

Bivariate Correlation

本章内容

第一节 线性相关

第二节 秩相关

线性相关 (linear correlation)


前提假设: (X, Y) 服从正态分布,

即适用于双变量正态分布资料


研究目的: 分析两个变量之间有无相关关系

相关系数: (linear correlation coefficient)


描述两变量间线性相关的密切程度
和相关方向的统计量




$$0 < r < 1$$




$$r = 1$$




$$-1 < r < 0$$




$$r = -1$$




$$r=0$$



$$r=0$$



$$r=0$$



$$r=0$$

线性相关系数计算

又称：积差相关系数(coefficient of product-moment correlation) / Pearson相关系数 / 相关系数

样本相关系数： r

总体相关系数： ρ

$$-1 \leq r \leq 1$$

$|r|$ 越大，线性
相关越密切

$$r = \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\sqrt{\sum (X - \bar{X})^2 \sum (Y - \bar{Y})^2}} = \frac{l_{XY}}{\sqrt{l_{XX} l_{YY}}}$$

相关系数的统计推断

(一) 相关系数的假设检验

$$t_r = \frac{r - 0}{s_r}$$

$$s_r = \sqrt{\frac{1 - r^2}{n - 2}}$$

(二) 查表法

- 查 r 界值表 (附表)

$$\nu = n - 2$$

第二节 秩相关

适用条件:

- ①资料不服从双变量正态分布而不宜作积差相关分析;
- ②总体分布型未知, 一端或两端是不确定数值(如 <10 岁, ≥ 65 岁)的资料;
- ③原始数据用等级表示的资料。

一、Spearman秩相关

1. 意义：等级相关系数 r_s 用来说明两个变量间直线相关关系的密切程度与相关方向。

2. 计算公式

3. 确定 P 值---查表

当 $n \leq 50$ 时，查附表的 r_s 界值表；

当 $n > 50$ 时，计算检验统计量 u 。

表2 急性白血病患儿的血小板($10^9/L$)和出血症状

病人编号	血小板数	秩次	p^2	出血症状	秩次	q^2	pq
	X	p		Y	q		
(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)=(3).(6)
1	121	1	1	+++	11.5	132.25	11.5
2	138	2	4	++	9.0	81	18
3	165	3	9	+	7.0	49	21
4	310	4	16	-	3.5	12.25	14
5	426	5	25	++	9.0	81	45
6	540	6	36	++	9.0	81	54
7	740	7	49	-	3.5	2.25	24.5
8	1060	8	64	-	3.5	12.25	28
9	1260	9	81	-	3.5	12.25	31.5
10	1290	10	100	-	3.5	12.25	35
11	1438	11	121	+++	11.5	132.25	126.25
12	2004	12	144	-	3.5	12.25	42
合计	—	78	650	-	78	630	451

- 利用表**2**中的数据容易算得

$$l_{pp} = 143$$

$$l_{qq} = 123$$

$$l_{pq} = -56$$

$$r_s = \frac{l_{pq}}{\sqrt{l_{pp}l_{qq}}} = \frac{-56}{\sqrt{143 \times 123}} = -0.422$$

秩相关系数为负，说明两变量间有负相关关系，
同样由样本算得的秩相关系数是否有统计学意义，
也应做检验

二 秩相关系数的统计推断

- 检验步骤

假设检验

$$H_0: \rho_s = 0, \quad H_1: \rho_s \neq 0$$

$$\alpha = 0.05$$

统计推断

当 $n \leq 50$ 时，可查书后的 r_s 临界值表，若秩相关系数超过临界值，则拒绝 H_0 ；当 $n > 50$ 时，也可采用 t 检验

例5 对例4的秩相关系数作假设检验

- 例4中算得 $r_s = -0.442$ 查 r_s 临界值表,
 $|r_s| < r_{12,0.1} = 0.503$, 按 $\alpha = 0.05$ 的水准, 不能拒绝 H_0 , 可以认为急性白血病患儿的出血症状与血小板数之间无相关关系

第一节 简单线性回归

双变量计量资料：每个个体有两个变量值

总体：无限或有限对变量值

样本：从总体随机抽取的n对变量值

(X_1, Y_1) , (X_2, Y_2) , ..., (X_n, Y_n)

目的：研究X和Y的数量关系

方法：回归与相关

简单、基本——直线回归、直线相关

相关系数反映了散点的疏密，一个变量对另一个变量的影响需用回归分析。

对于线性回归，若只有1个自变量，称为简单回归(simple regression)；若有2个或2个以上自变量，称为多重回归(multiple regression)。

当这种数量关系为曲线关系时，称为曲线回归/非线性回归(curve regression/nonlinear regression)。

简单线性回归模型

$$Y_i = \alpha + \beta X_i + \varepsilon_i$$


样本线回归方程

$$\hat{Y} = a + bX$$


$\hat{Y}$ 为各X处Y的总体均数的估计。

线性回归模型的假设条件

- **1.线性(line)** 自变量和因变量之间的关系有线性趋势 **散点图**
- **2.独立(independence)** n 个个体之间相互独立 **专业知识,残差图**
- **3.正态(normal)** 各 x 所对应的 y 服从正态
(误差项服从正态分布)
残差的直方图,正态概率图
- **4. 等方差(equal variance)** 各 x 值变动时,相应的 y 有相同的变异性
散点图,残差图



最小二乘法(least square method)




回归参数的估计方法

$$b = \frac{l_{XY}}{l_{XX}} = \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\sum (X - \bar{X})^2}$$

$$a = \bar{Y} - b \bar{X}$$

式中 l_{XY} 为 X 与 Y 的离均差乘积和：

$$l_{XY} = \sum (X - \bar{X})(Y - \bar{Y}) = \sum XY - \frac{(\sum X)(\sum Y)}{n}$$



回归方程的假设检验

建立样本直线回归方程，只是完成了统计分析中两变量关系的统计描述，研究者还须回答它所来自的总体的直线回归关系是否确实存在，即是否对总体有 $\beta \neq 0$?





图9-3 总体回归系数与样本回归系数示意图

(一)、方差分析法



因变量Y的变异分解图示

◆ l_{YY} 的分解:

$$Y - \bar{Y} = \left(\hat{Y} - \bar{Y} \right) + \left(Y - \hat{Y} \right)$$

$$\sum (Y - \bar{Y})^2 = \sum (\hat{Y} - \bar{Y})^2 + \sum (Y - \hat{Y})^2$$

表示为:

$$\text{SS总} = \text{SS回} + \text{SS剩}$$

◆ $v_{\text{总}} = v_{\text{回}} + v_{\text{剩}}$

$$(v_{\text{总}} = n - 1, v_{\text{回}} = 1, v_{\text{剩}} = n - 2)$$

- $SS_{\text{总}}$ 是Y的离均差平方和, 表示Y的总变异。
- $SS_{\text{回}}$ 表示在Y的总变异中可用X来解释的部分, 即使得总变异 $\sum (Y - \bar{Y})^2$ 减少的那部分。

$SS_{\text{回}}$ 越大, 说明回归效果越好。

$$SS_{\text{回}} = b l_{XY} = \frac{l_{XY}^2}{l_{XX}}$$

- $SS_{\text{剩}}$ 表示在Y的总变异中无法用X解释的部分, 即除了X对Y的线性影响外, 其它一切因素对Y变异的作用。

$$F = \frac{SS_{\text{回}} / \nu_{\text{回}}}{SS_{\text{剩}} / \nu_{\text{剩}}} = \frac{MS_{\text{回}}}{MS_{\text{剩}}}$$

(二) t 检验

$$t = \frac{b-0}{S_b} = \frac{b}{S_{Y.X} / \sqrt{l_{XX}}}$$

$$S_{Y.X} = \sqrt{\frac{\sum (Y - \hat{Y})^2}{n-2}} = \sqrt{\frac{SS_{\text{剩}}}{n-2}}$$

H_0 、 H_1 及 α 同方差分析，代入公式求得
 $t=4.579$, 自由度 $= 8-2=6$ ，查t界值表
得 $0.002 < P < 0.005$ ，结论同上。

注意

- 对同一份资料， $F=t^2$, F检验与t检验所得的结论一致。
- 回归系数的检验与相关系数的检验结论一致。

(1) 方差分析

$H_0: \beta = 0$ ，即凝血酶浓度与凝血时间)之间无直线关系

$H_1: \beta \neq 0$ ，即凝血酶浓度与凝血时间数据之间有直线关系

$$\alpha = 0.05$$

方差分析表

变异来源	自由度	SS	MS	F	P
总 变 异					
回 归					
残 差					

$\nu_1=1$ 、 $\nu_2=6$ ，查 F 界值表，得 $P < 0.01$ 。按 $\alpha = 0.05$ 水准拒绝 H_0 ，接受 H_1 ，可以认为尿肌酐含量与年龄之间有直线关系。

(2) t 检验

参数 β 的意义是：若自变量 X 增加一个单位，反应变量 Y 的平均值便增加 β

$$t_b = \frac{b - \beta}{S_b}$$

$$t_b = \frac{-6.98020}{0.78655} = -8.87$$

$\nu = 13$ ，查 t 界值表，得 $P < 0.001$ 。按 $\alpha = 0.05$ 水准，拒绝 H_0 ，接受 H_1 。

注意：

$\sqrt{F} = t$ ，即直线回归中对回归系数的 t 检验与 F 检验等价，类似于两样本均数比较可以作 t 检验亦可作方差分析。

决定系数(coefficient of determination)

R^2 定义为回归平方和与总平方和之比，计算公式为：

$$R^2 = \frac{SS_{\text{回}}}{SS_{\text{总}}} = \frac{l_{XY}^2 / l_{XX}}{l_{YY}} = \frac{l_{XY}^2}{l_{XX} l_{YY}}$$

取值在0到1之间且无单位，其数值大小反映了回归贡献的相对程度，也就是在Y的总变异中回归关系所能解释的百分比。

相关与回归的区别与联系



区别

- 两个变量的地位
- 用途
- 相关系数与回归系数的取值范围
- 相关系数与回归系数的单位



联系

➤ 相关系数与回归系数的计算公式

$$r = \frac{l_{XY}}{\sqrt{l_{XX}l_{YY}}} = \frac{l_{XY}}{l_{XX}} \frac{\sqrt{l_{XX}}}{\sqrt{l_{YY}}} = b \sqrt{\frac{l_{XX}}{l_{YY}}}$$

$$b = \frac{l_{XY}}{l_{XX}} = \frac{l_{XY}}{\sqrt{l_{XX}l_{YY}}} \frac{\sqrt{l_{YY}}}{\sqrt{l_{XX}}} = r \sqrt{\frac{l_{YY}}{l_{XX}}}$$

➤ 相关和回归的假设检验是等价的

$$r^2 = \frac{l_{XY}^2}{l_{XX}l_{YY}} = \frac{l_{XY}^2 / l_{XX}}{l_{YY}} = \frac{SS_{\text{回}}}{SS_{\text{总}}}$$