

生物统计学

Biostatistics

阎玉霞

Department of Biostatistics

课前说明

- 参考教材
 - 生物统计学：颜艳,王彤. 医学统计学-第五版[M]. 人民卫生出版社,2020.
- 每个教班选课代表1名，入课代表群
- 生物统计学系：61648319 邓老师



成绩考核标准

过程性评价成绩


1 作业 15%

2 视频 5%

3 线上自主学习 10%（主要利用24小时AI智能学伴功能，提问课程知识，并反馈回答是否准确。学期末我们会从AI后台导出教学数据，根据提问次数给出成绩[参考了中山大学课程考核标准]）


终结性评价

期末 70%



No. Questions	Score
<10 questions	1
10-15	2
16-20	3
21-25	4
26-30	5
31-35	6
36-40	7
41-45	8
46-50	9
>51	10

雨课堂界面



雨课堂界面

1 24 h 智能助手（用于答疑解惑）

2 AI 陪练（用于自主练习）

雨课堂界面

雨课堂 医学统计学

开放型作业 作业1 AI智能体

作业是智能体

3 智能体作业（用于案例分析）

- 根据题目和提示进行对话
- 可以进行多次尝试
- 作业占比15%

 格物致统 (计数资料统计描述) 清空

你好！我是医学统计学统计咨询师，专注于帮你解决课程学习中的疑问。无论是统计概念、习题解答、方法选择，还是软件操作相关问题，都可以告诉我。我会通过提问引导你自主思考、解决问题，请在最后输入“结束对话”获取智能体对话评分和评语。

同学你好呀！欢迎来到《医学统计学》辅助学习课堂。

咱们今天先来看一个非常经典的临床案例，很多初学者都容易在这里“踩坑”哦：

某医院报告：2024年共开展300例腹腔镜胆囊切除术，发生胆管损伤6例，其中3例来自本院培训期间主刀医生，3例来自外院进修医生。由于本院医生占比为60%，外院为40%，但外院医生造成的损伤构成比达到50%，说明外院医生技术水平显著较差。

针对这个案例，我想请你思考三个问题：

1. “胆管损伤发生率”到底应该怎么算？案例里给出的那个数据，究竟是“率”还是“构成比”呢？
2. 如果真想比较这两组医生的损伤风险谁高谁低，你觉得我们还缺什么关键信息？
3. 你能看出上面这段结论里，藏着什么统计学上的错误吗？

别急着要答案，试着结合课本上关于“相对数”的知识点想一想。你可以先挑一个你最有把握的问题聊聊你的思路，或者说哪里觉得困惑，我们一步步来梳理，好吗？



课程安排

- 第一部分 统计基础理论课（暑假自学+3次复习串讲）

课程序号	内容
1	绪论，有关基本统计学概念 统计描述(定量/定性资料，统计图表) 正态分布与参考值范围估计
2	抽样误差+参数估计+ t检验 行列表的卡方检验
3	基于秩次的非参数检验 简单相关与回归

课程安排

• 第二部分 统计学高级部分

序号	内容
4	方差分析1（1way和2way串讲复习/析因设计）
5	方差分析2（重复测量/拉丁方*/crossover*）
6	多重线性回归+协方差分析(曲线拟合*)
7	危险度分析+logistic回归分析
8	习题课（线上）
9	生存分析
10	判别与聚类（线上）
11	研究设计1（调查研究）
12	研究设计2（实验+临床）
13	量表制作与评价（线上）
14	诊断试验中的统计简介/总复习
15	医学论文中的统计学表达
16	生物统计学考试

统计学基本概念



A 同质： (**homogeneity**)事物的性质、影响条件或背景相同或非常相近

变异： (**variation**)同质个体间的差异

例1 调查2004年某市7岁男童的身高和体重

同质： 2004年、某市、7岁男童

变异： 身高和体重各不相同

例2 研究某降压药的疗效

同质： 高血压患者、用某药治疗

变异： 疗效各不相同

B 随机事件：在一定条件下可能发生的事件

随机变量： (**random variable**) 随机事件在数量上的表现

离散型变量： (*discrete variable*) 在一定区间内变量取值为有限个，或数值可以一一列举出来

连续型变量： (*continuous variable*) 在一定区间内变量取值有无限个，或数值无法一一列举出来

有序变量： (*ordinal variable*)


C 总体: (population) 根据研究目的所确定的
同质观察单位的全体

样本: (sample) 从总体中随机抽取的部分观察单位



D 参数: (parameter) 总体的某种统计特征值

统计量: (statistic) 根据样本数据计算出的一个量



E 概率： (**probability**) 度量随机事件发生可能性大小的一个数值，用大写的**P**表示；取值**[0, 1]**。


必然事件： $P=1$

不可能事件： $P=0$

频率： (**frequency**) 事件实际发生次数与可能发生次数的比率，设在相同条件下，独立重复进行**n**次试验，事件A出现**f**次，则事件A出现的频率为 f / n 。

★重要结论： 小概率事件很难发生！

F 误差: (error) 指观察真值与观察值之差,
或样本指标与总体指标之差。



随机误差 (random error)

重复测量误差 (error of replication)

抽样误差 (sampling error)

由于抽样所导致样本指标与总体指标的差异（主要由变异引起）

特点：无倾向性；不可避免。

统计资料的数据类型

A 计数资料: (*count data*)

又称定性资料 (**Qualitative data**) , 分二分类和多分类, 按观察单位品质标志分组, 再清点各组的例数所得的资料。

特点: 一般无固有计量单位,

如: 心电图检查结果 (正常、异常)

性别 (男、女)

血型 (A、B、O、AB)

职业 (工、农、兵)

(离散型)

统计资料的数据类型

B 计量资料: (*measurement data*)

又称定量资料，用仪器、工具等定量方法对观察单位测量(measure)某指标值所得到的资料。

特点：一般有计量单位，

如：患者身高(cm)、体重(kg)、血压(mmHg)、脉搏(次/分)、红细胞计数(10^{12} /L)等；

(连续型)

统计资料的数据类型


C 等级资料: (*ordinal data*)

又称半定量半定性资料，根据观察单位某指标量的大小，深浅或严重程度分组，得到的各等级组观察单位数。

特点：有大小顺序，故又称有序分类资料
(*ordinal category data*)。

- 如 ① 癌症分期：早、中、晚；
② 药物疗效：治愈、好转、无效、死亡；
③ 尿蛋白：-, ±, +, ++, +++及以上；
(有序型)

统计描述 ← **统计分析** → 统计推断



描述集中趋势

平均数： (average)描述一组同质计量资料的集中趋势(central tendency)。

1. 算术均数(arithmetic mean)/均数(mean)
2. 几何均数(geometric mean)
3. 中位数 (median)

平均数指标小结

平均数是描述频数分布集中位置，
代表一组观察值的平均水平。

平均数	意义	应用场合
均数	平均数量水平	适用于正态分布或近似正态分布的资料。
几何均数	平均增（减）的倍数	适用于等比级数的资料及对数正态分布的资料。
中位数	位次居中的观察值水平	适用于偏态分布的资料。

离散趋势的描述（变异指标）

反映数据的离散度(**Dispersion**), 即个体观察值的变异程度。常用的有:

1. 极差(*Range*)/全距

2. 百分位数与四分位数间距

Percentile and Quartile range

3. 方差与标准差

Variance and Standard Deviation

4. 变异系数 (*Coefficient of Variation*)

变异指标

1. **极差**较粗，适合于任何分布
2. **标准差**与均数的单位相同，适合于近似正态分布
3. **变异系数**主要用于单位不同或均数相差悬殊资料
4. 平均指标和变异指标分别反映资料的不同特征，
常配套使用，如**正态分布**：均数、标准差
偏态分布：中位数、四分位数间距

计数资料的常用统计指标

常用相对数(relative number)

- 比
- 构成比
- 率
- 动态数列

➤ **比 (ratio) / 相对比 (relative ratio) :**

任两个数A与B的比, 说明A是B的若干倍或几分之几, 通常用倍数或分数表示。 **比=A:B**

- 对同质的: 说明两者间的差别或比例关系

如: 男同学:女同学, 医生:护士, 教师:学生

- 对不同质的: 表示一个量A相对于另一个量B的对比数

如: 人口数: 医生数, 人口数: 病床数

$$\text{体重指数} = \text{体重} / (\text{身高})^2 \quad (\text{kg/m}^2)$$

➤ 构成比：说明某一事物内部，各组成部分所占的**比重**，也叫比率。

$$\text{构成比} = \frac{\text{某一组成部分的观察单位数}}{\text{同一事物各组成部分的观察单位总数}} \times 100\%$$

如：及格率 = (及格人数/参加考试人数) × 100%
教研室16人中教授有4人，占20%。

➤ 构成比没有单位， **$0 \leq \text{构成比} \leq 1$**

率（rate）：说明某现象或事物发生的**频率**
或**强度**，又称为**强度相对数**。

率 = （实际发生数 / 可能发生总数） × 比例基数

比例基数：100%、1000‰、10000/万等

如：发病率、死亡率、感染率、阳性率等

死亡率 = (死亡人数 / 总的人口数) × 100000 / 10万

统计图表

- 一. 统计表(statistical table) —— 数据代替文字描述，便于统计结果的精确、简洁的表达和对比分析
- 二. 统计图(statistical chart) —— 图形代替数据，获得直观、形象的效果

一. 统计表

1. 统计表的结构

2. 统计表的种类

1. 统计表的结构

标题、标目、线条、数字、备注

表号		标题（何时、何地、何事）	
横标题目		纵标题目	合计
横标目 ⋮ 合计	×××	×××	×××
	⋮	数字	⋮
	×××	×××	×××
合计		×××	×××

顶线

底线

备注：

2. 统计表的类型

- 简单表(**simple table**):

只按一个特征或标志分组

- 组合表(**combinaive table**):

- 按两个或多个特征或标志结合分组

二. 统计图

条图

圆图

百分比图

线图

半对数线图

散点图

直方图

.....

统计图的结构

- 
1. 标 题
 2. 图 域
 3. 标 目
 4. 尺 度
 5. 图 例

1. 条图(bar chart)

用等宽的直条**长度**表示事物的数量
适用：比较多个相互独立得统计指标




图 某年某市某区几种主要疾病死亡专率(1/10万)

复式条图




图 某工厂职工1994、1998年四项生理指标异常检出率

2. 圆图(pie chart)

圆图：用于表达事物内部的百分构成比大小。

- 各个扇形面积的大小（即圆心角的度数， 3.6° ）反映各组成部分百分比（ 1% ）的大小。
- 从12点钟处开始绘制，**顺时针**方向排列。

3. 百分条图（percent bar graph）

作用与圆图相同, 但更适用于多组百分比的比较。

表 甲、乙两疗法治疗某病疗效构成

疗 效	甲疗法		乙疗法	
	例数	构成比(%)	例数	构成比(%)
控制	48	46.2	40	40.0
有效	24	23.0	14	14.0
显效	24	23.0	26	26.0
无效	8	7.8	20	20.0
合计	104	100.0	100	100.0

5. 半对数线图(semi-logarithmic line graph)

表示事物的发展速度(相对比)。

纵轴：对数尺度；

横轴：连续性变量（时间、年龄等）。

适用：两组数据
相差悬殊。






图4-11 某地某年食管癌年龄别性别发病率(1/10万)

**表* 某市1949~1957年15岁以下儿童结核病
和白喉死亡率(1/10万)**

年份	结核病死亡率	百喉死亡率
1949	150.2	20.1
1950	148.0	16.6
1951	141.0	14.0
1952	130.0	11.8
1953	110.4	10.7
1954	98.2	6.5
1955	72.6	3.9
1956	68.0	2.4
1957	54.8	1.3



图* 某市 1949~1957 年儿童结核病和白喉死亡率



图** 某市 1949~1957 年儿童结核病和白喉死亡率

6. 直方图(histogram)

用矩形面积表示连续变量的频数(频率)分布。


1. 横轴：连续变量的组段；

纵轴：频数或频率，尺度从0开始。

2. 各矩形条之间不留空隙。

3. 矩形的高度为频数或频率，宽度为组距。

4. 当各组的组距不等时，不能直接用各组频数绘图，而应先将频数除以组距作高度再作图。



7. 散点图(scatter plot)

用点的密集程度和趋势表示两种现象间的相关关系。

横轴：自变量X，纵轴：应变变量Y

纵轴与横轴的起点可根据资料的情况而定。





图 15例健康成人凝血时间与凝血酶浓度数据的散点图

8. 箱图(boxplot)

箱图 (boxplot) 也称箱须图 (box-whisker plot)，用于反映一组或多组连续型定量数据分布的中心位置和散布范围。



正态分布与医学参考值范围

*normal distribution &
medical reference range*

正态分布

正态分布（normal distribution）也叫高斯分布（Gaussian distribution），是最常见、最重要的一种连续型分布。


一、正态分布的数学形式

二、标准正态分布

三、曲线下面积


四、正态性检验

五、正态分布的应用



一. 正态分布的数学形式

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$



$$-\infty < x < +\infty$$

正态分布的特征


1. 正态曲线位于直角坐标系上方，以 $X=\mu$ 为中心，左右对称，两端以 x 轴为渐进线。

2. 在 $X=\mu$ 处 $f(x)$ 取最大值， $f(\mu)=1/\sigma\sqrt{2\pi}$;

x 越远离 μ ， $f(x)$ 值越小。

3. 位置参数 μ ,

形态参数 σ






图 正态分布位置变换示意图




图 正态分布形态变换示意图

二. 标准正态分布 (standard normal distribution)

两个参数: $\mu=0, \sigma=1$, 记为 $N(0,1)$

经u变换: 一般正态分布 $N(\mu, \sigma^2)$


转化为标准正态分布 $N(0,1)$; 其中 $u = \frac{X - \mu}{\sigma}$

$$f(u) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{u^2}{2}\right), \quad -\infty < X < \infty$$

一般正态分布
 $N(\mu, \sigma^2)$

$$u = \frac{X - \mu}{\sigma}$$

标准正态分布
 $N(0, 1)$




三. 曲线下面积


附表 标准正态曲线下面积 $\Phi(-u)$

u	0.00	0.01	0.02		0.06	0.07	0.08	0.09
-3.0	0.0013	0.0013	0.0012		0.0011	0.0011	0.0010	0.0010
-2.9	0.0019	0.0018	0.0018		0.0015	0.0015	0.0014	0.0014
.....								
-2.5	0.0062	0.0060	0.0059		0.0052	0.0051	0.0049	0.0048
.....								
-1.9	0.0287	0.0281	0.0274		0.0250	0.0244	0.0239	0.0233
.....								
-0.1	0.4602	0.4562	0.4522		0.4364	0.4325	0.4286	0.4247
0.0	0.5000	0.4960	0.4920		0.4761	0.4721	0.4681	0.4641

曲线下面积分布规律



$N(\mu, \sigma^2)$



$\mu - 2.58\sigma$ $\mu - 1.96\sigma$ $\mu - \sigma$ μ $\mu + \sigma$ $\mu + 1.96\sigma$ $\mu + 2.58\sigma$


四. 正态性检验(normality test)

正态分布的两个特征：1. 正态对称性

2. 正态峰：偏度、峰度

方法：1. 图示法 Q-Q图，P-P图

2. 计算法







图 108个原始数据的Q-Q图

Normal P-P Plot of BLOOD



正态分布的应用

1. 估计医学参考值范围：利用正态曲线面积分布规律；
2. 质量控制：如控制实验中的随机误差；
3. 正态分布是许多统计方法的理论基础：如 t 分布、 χ^2 分布、 F 分布等都是正态分布的基础上推导出来的。

医学参考值范围

Medical reference range

参考值 (reference value) 范围 (传统叫法“正常值范围”) 指个体观察值的散布范围。

如成人红细胞的总数 $4000 \sim 10000$ 个/ mm^3


概念扩展: 规定食品、空气、水、土壤等卫生标准;

流行病学: 据潜伏期确定接触者的留验期限。


参考值范围

步骤:


1. 从“正常人”总体中抽样：明确研究总体；
2. 统一测定方法以控制系统误差；
3. 判断是否需要分组（如性别、年龄）确定；
4. 根据专业知识决定单侧还是双侧。



单侧上限



单侧下限




双侧下限

双侧上限

参考值范围的计算

- 方法：
1. 正态分布法
 2. 百分位数法

1. 正态分布法——适用于正态分布资料



双侧(1- α)正常值范围: $\bar{X} \pm u_{\alpha/2}S$
单侧(1- α)正常值范围: $< \bar{X} + u_{\alpha}S$ (上限)
 $> \bar{X} - u_{\alpha}S$ (下限)

双侧95%正常值范围: $\bar{X} \pm 1.96S$
单侧95%正常值范围: $< \bar{X} + 1.64S$ (上限)
 $> \bar{X} - 1.64S$ (下限)

2. 百分位数法

适用于偏态分布资料

双侧95%正常值范围: $P_{2.5} \sim P_{97.5}$

单侧95%正常值范围: $< P_{95}$ (上限)

$> P_5$ (下限)

1. 直接计算

2. 频数表法

例 某地调查正常成年男子144人的红细胞数，近似正态分布，得均数537.8万/mm³，标准差为43.9万/mm³。试估计该地正常成年男子红细胞计数的95%参考值范围。

$$\bar{X} - 1.96S = 537.8 - 1.96 \times 43.9 = 451.8(\text{万/mm}^3)$$

$$\bar{X} + 1.96S = 537.8 + 1.96 \times 43.9 = 623.8(\text{万/mm}^3)$$

故该地正常成年男子红细胞的计数的95%参考值范围是 451.8~623.8万/mm³

小 结

- 1 正态分布的特征
- 2 正态分布的标准化变换
- 3 正态分布曲线下面积分布规律
- 4 参考值范围的概念及计算